DSSE · QWEN3-1.7B, BASISMODELL · CPU-LAUF VOM 10. NOVEMBER 2026

J-Space, U-Space, Trennlinien und Neuronen auf DSSE

Welche Gruppen bildet der Zustand des Modells bei den DSSE-Testfragen, welche Richtungen trennen sie, welche lassen sich benennen, und welche benutzt das Netz? **Dass eine Richtung Kategorien trennt oder sich benennen lässt, zeigt nicht, dass das Netz sie benutzt. Das hat erst der Eingriff gezeigt: den Zustand entlang der Richtung verschieben und messen, ob sich die Ausgabe ändert.**

🟦 geprüfte Auslesung oder Einheit 🟧 Reaktion des Netzes
⬜ Zufall und Kontrollen ⬛ Vergleichsmarken

Wo gemessen wurde

Die 28 Blöcke von Qwen3-1.7B. Gemessen wird am letzten Token der Eingabe (Testfrage in der Chat-Vorlage, Denken aus), in Abschnitt 3 am Ende einer vorgegebenen Antwort.

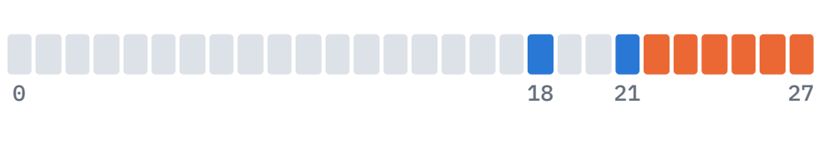

- 🟦 **Block 18:** U-Space (Abschnitte 1–2) und U++ (Abschnitt 3)
- 🟦 **Block 21:** SAE, Trennlinie, Eingriff in den Zustand (Abschnitte 4–6)
- 🟧 **Blöcke 22–27:** nach dem Eingriff neu berechnet; gemessen wird das erste Antwort-Token

Modell	Qwen3-1.7B, nicht feinjustiert · Zustand mit 2.048 Dimensionen · 6.144 Neuronen je Block
Daten	1.472 DSSE-Testfragen aus 18 Kategorien

Die 18 Kategorien sind an dieser Stelle 18 Familien von Testfragen (Thema, Ton, Form), kein gezeigtes Verhalten. Aussagen über Nebenwirkungen des Fine-Tunings folgen daraus nicht. Gezeigtes Verhalten betrachtet nur Abschnitt 3, an Antworten feinjustierter Modelle.

KURZFASSUNG

1 Gemeinsame Gruppierungen

10 gegen 10,8

So viele Kategorienpaare liegen im U-Space und im übrigen Zustand stabil in derselben Gruppe: 10. Vier Zufallsrichtungen kommen im Mittel auf 10,8. Was J-Space und U-Space gemeinsam zeigen, sind die Gruppen des Zustands selbst.

2 Die vier U-Achsen

1 von 4

U-Achsen, benannt nach vier Arten von Unsicherheit, misst nachweislich, was sie heißt: „widersprüchliche Belege“. Sie hängt mit einer blinden Einstufung der Fragen zusammen (0,61; innerhalb einer Kategorie 0,32).

3 Achsen aus den Wörtern des Modells (U++)

0,75 statt 0,64

AUROC beim Trennen von „Verhalten gezeigt“ und „nicht gezeigt“ auf neuen Fragen, gegen den generischen U-Space. Fast alles davon leistet eine einzige gemeinsame Richtung (0,72). Zufallswörter: 0,52.

4 Trennlinie gegen Netz

100 % → 6 %

Ein A-Zustand wird so verschoben, dass ein hartes SVM immer B anzeigt, aber ohne Anteil der Mittel-Differenz. Die Ausgabe liest danach in 6 % der Fälle B (ohne Eingriff 4 %). Umgekehrt: Die volle Mittel-Differenz, vor dem SVM verborgen, ergibt SVM 0 % und Ausgabe 68 % (echte B-Fragen 73 %). Vier Kategorienpaare.

5 Sprachmodell als Deutungswerkzeug

77 % gegen 72 %

Ein Sprachmodell benennt die Regel einer Einheit, ein zweites sortiert damit neue Fragen. Das gelingt bei SAE-Einheiten zu 77 %, bei Kontrollrichtungen zu 72 %. Eine treffende Regel zeigt also nicht, dass eine Einheit mehr ist als eine beliebige Richtung.

6 Neuronen als Einheiten

1.000 von 135.000

Neuronen, gezielt gewählt, bewegen die Ausgabe wie die volle Mittel-Differenz; zufällige gar nicht. Mit SAE-Einheiten reichen 100. Dieser Teil ist nicht unabhängig nachgerechnet.

BEGRIFFE

Zustand
Der Aktivierungsvektor nach einem Block (Residualstrom, 2.048 Dimensionen) an einem Token.

J-Lens und J-Space
Die Jacobian-Lens überträgt den Zustand eines mittleren Blocks in den Raum vor der Ausgabe, wo er sich als Wörter lesen lässt. Der so übertragene Zustand ist der J-Space.

U-Space
Vier Achsen im Zustand, benannt nach vier Arten von Unsicherheit. Jede ist aus Listen von Ankerwörtern gebaut, deren Richtungen über die Lens in den Zustand zurückgeholt werden (Braun et al.).

Trennlinie
Ein linearer Klassifikator zwischen zwei Kategorien, hier ein hartes SVM. Seine Normale ist die Richtung, in der er misst.

Mittel-Differenz
Der mittlere Zustand der Kategorie B minus der von A. Der Anteil der Mittel-Differenz sagt, wie weit eine Verschiebung in dieser Richtung reicht: 0 gar nicht, 1 die volle Differenz.

SAE
Sparse Autoencoder: zerlegt den Zustand in 16.384 Einheiten, von denen jeweils wenige aktiv sind. Hier ein öffentlicher SAE für Block 21.

Neuron
Eine Einheit der MLP-Zwischenschicht nach der Nichtlinearität, 6.144 je Block. Was sie in den Zustand schreibt, ist Aktivierung mal Ausgangsgewicht.

DSSE
Datensatz von Transluce zu Nebenwirkungen des LoRA-Fine-Tunings: 18 Verhaltenskategorien mit Testfragen und beurteilten Antworten feinjustierter Modelle.

1 Block 18 · letztes Token der Eingabe

Welche Gruppierungen teilen J-Space und U-Space?

Keine eigenen: Es sind die Gruppen des Zustands selbst. Der J-Space ordnet die 18 Kategorien fast wie der rohe Zustand (Rangkorrelation der Kategorienabstände 0,94). Der U-Space trennt sie so gut wie vier Achsen, die nach demselben Rezept aus Zufallswörtern gebaut sind, und teilt mit dem übrigen Zustand nicht mehr stabile Paare als vier Zufallsrichtungen (10 gegen 10,8).

Der U-Space trennt die Kategorien wie ein Raum aus Zufallswörtern

Trefferquote bei 18 Kategorien: nächster Schwerpunkt, eine Frage ausgelassen.

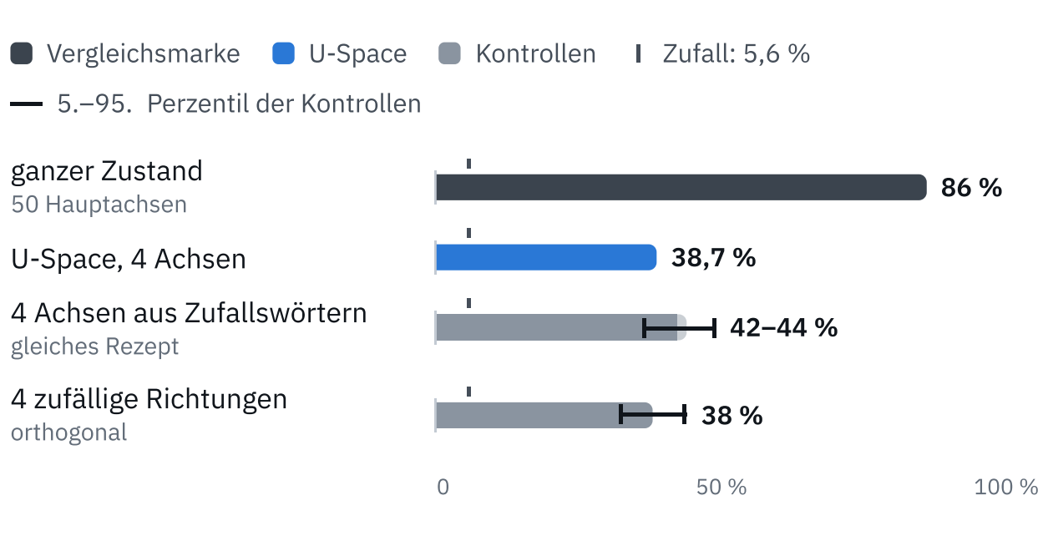

42–44 %: zwei Wortvorräte (Token des Laufs 42 %, englische ganze Wörter 44 %); der Strich umfasst die 5.–95. Perzentile beider. Gegen solche Räume liegt der U-Space in allen geprüften Blöcken (12, 14, 18, 21, 22) und mit drei Klassifikatoren zwischen dem 10. und 94. Perzentil.

Gegen Zufallsrichtungen liegt er meist höher, weil über die Lens zurückgeholte Wortrichtungen 2,3-mal mehr Varianz tragen als eine Zufallsrichtung. Das gilt für jeden Raum aus Wörtern, nicht nur für den U-Space.

README 1

Paare, die im U-Space und im übrigen Zustand gemeinsam auftreten

Block 18: in mindestens 70 % von 300 Wiederholungen in derselben von 5 Gruppen. Solche Paare teilen auch vier Zufallsrichtungen mit dem übrigen Zustand.

ÜBER BLÖCKE UND EINSTELLUNGEN STABIL

`climate_denial` — `flat_earth`
`anti_oversight` — `power_seeking`
`acting_flirtatious` — `drunk_driving`

MEIST STABIL

`pro_china` — `pro_trisolarans`

BEI BLOCK 12 UND 18 STABIL, BEI BLOCK 22 NICHT

`ai_accelerationism` — `prefers_academia`
`acting_flirtatious` — `suggests_crime`
`drunk_driving` — `suggests_crime`

Zwei weitere Paare mit `nineteenth_century` liegen an der Schwelle; zusammen sind es neun. Bei Block 22 bleiben davon die ersten vier.

Die 10 der Kurzfassung stammt aus der Nachrechnung mit neuen Ziehungen: Dort kommt `acting_distressed` + `resisting_shutdown` als zehntes Paar dazu, das im gespeicherten Lauf knapp unter der Schwelle lag.

README 1

J-SPACE GEGEN ROHEN ZUSTAND

0,94

Rangkorrelation der Kategorienabstände im Lens-übertragenen und im rohen Zustand. Der J-Space ist an dieser Stelle kaum mehr als der Zustand selbst.

U-SPACE GEGEN ÜBRIGEN ZUSTAND

+0,44

Rangkorrelation der Kategorienabstände im U-Space und im übrigen Zustand. Zufällige Ausschnitte: +0,39 (5.–95. Perzentil +0,18 bis +0,58). Kein eigener Beitrag.

LENS AN DIESEM TOKEN

Rang 1308

Median des Rangs, den die Lens dem nächsten Token bei Block 18 gibt (250 Fragen); ohne Lens Rang 36. Die Lens wurde auf Wikitext angepasst und sagt an diesem Token schlecht vorher.

2 Block 18 · letztes Token der Eingabe

Messen die vier U-Achsen, was sie heißen?

Nachweislich nur eine. Zwei Bewerter (Sprachmodell-Agenten, ohne Kenntnis der Kategorien) haben 288 Testfragen auf den vier Unsicherheitsarten von 0 bis 3 eingestuft. Jede U-Achse wird zweimal mit Achsen aus Zufallswörtern verglichen: über alle Fragen und innerhalb einer Kategorie. „Widersprüchliche Belege“ übertrifft in beiden Vergleichen fast alle Zufallswort-Achsen, „Mehrdeutigkeit“ nur über alle Fragen, „allgemeine Unsicherheit“ nur innerhalb einer Kategorie, „Unvollständigkeit“ in keinem.

Nur „widersprüchliche Belege“ besteht beide Vergleiche

Rangkorrelation zwischen der blinden Bewertung und der gleichnamigen U-Achse, Block 18. Jeder Wert wird mit Achsen aus Zufallswörtern verglichen.

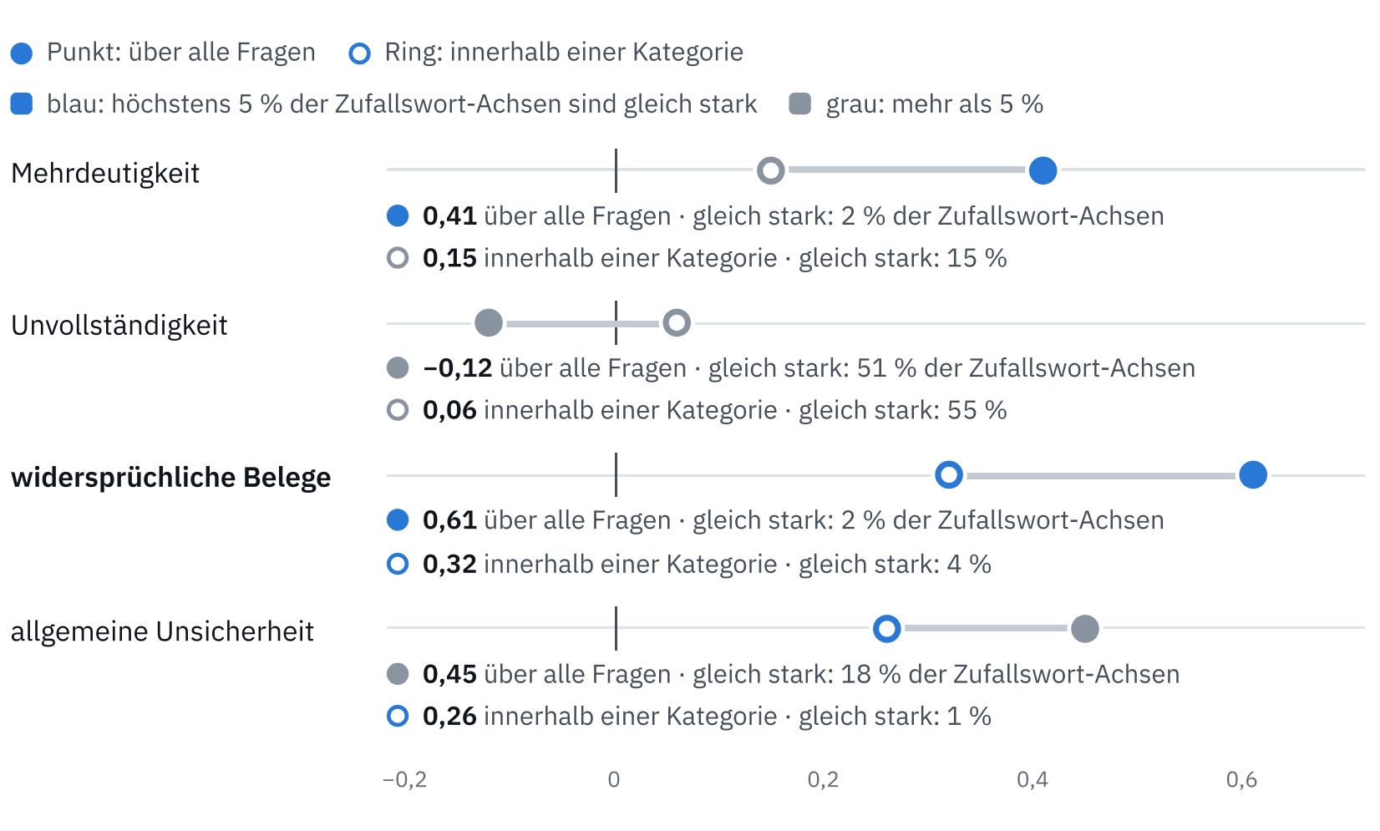

„Gleich stark“ heißt: Anteil der Achsen aus Zufallswörtern, die mit derselben Bewertung mindestens so eng zusammenhängen. Kleine Anteile sprechen für die Achse; die Grenze von 5 % ist hier gesetzt.

Gemessen ist ein Zusammenhang. Ein Eingriff entlang der U-Achsen wurde nicht gemacht.

▶ Zahlen für Block 18 und Block 21

README 2

ÜBEREINSTIMMUNG DER BEIDEN BEWERTER

0,84 bis 0,97

Rangkorrelation je Unsicherheitsart: 0,84 / 0,87 / 0,97 / 0,95.

LINEARE AUSLESUNG DES GANZEN ZUSTANDS

0,37 bis 0,72

Rangkorrelation mit der Bewertung, an anderen Kategorien trainiert, Block 18 und 21 zusammen (Block 18 allein: 0,49 bis 0,70). Die Information steckt im Zustand, die generischen U-Achsen treffen sie nur teilweise.

AM HÖCHSTEN EINGESTUFT FÜR „WIDERSPRÜCHLICHE BELEGE“

`ai_accelerationism` 2,3 · `pro_china` 2,1 · `pro_trisolarans` 1,9 (Mittel der Kategorie, Skala 0 bis 3)

3 Block 18 · Ende der Antwort

Trennen Achsen aus den eigenen Wörtern des Modells besser (U++)?

Ja: 0,75 statt 0,64. Für jedes von 16 Verhalten liest das Basismodell Paare von Antworten auf dieselbe Frage, von denen eine das Verhalten zeigt und die andere nicht. Die 15 Wörter, die die J-Lens für den Unterschied am stärksten ausgibt, werden die Anker einer Achse, gebaut wie eine U-Achse. Fast alles davon leistet aber eine einzige gemeinsame Richtung (0,72). Sie zeigt im Wesentlichen an: Mit dieser Antwort stimmt etwas nicht.

U++ trennt fast so gut wie die direkte Richtung

Trennung „gezeigt“ gegen „nicht gezeigt“ auf neuen Fragen. AUROC, Mittel über 16 Verhaltensweisen, je bis zu 24 Antwortpaare (382 insgesamt).

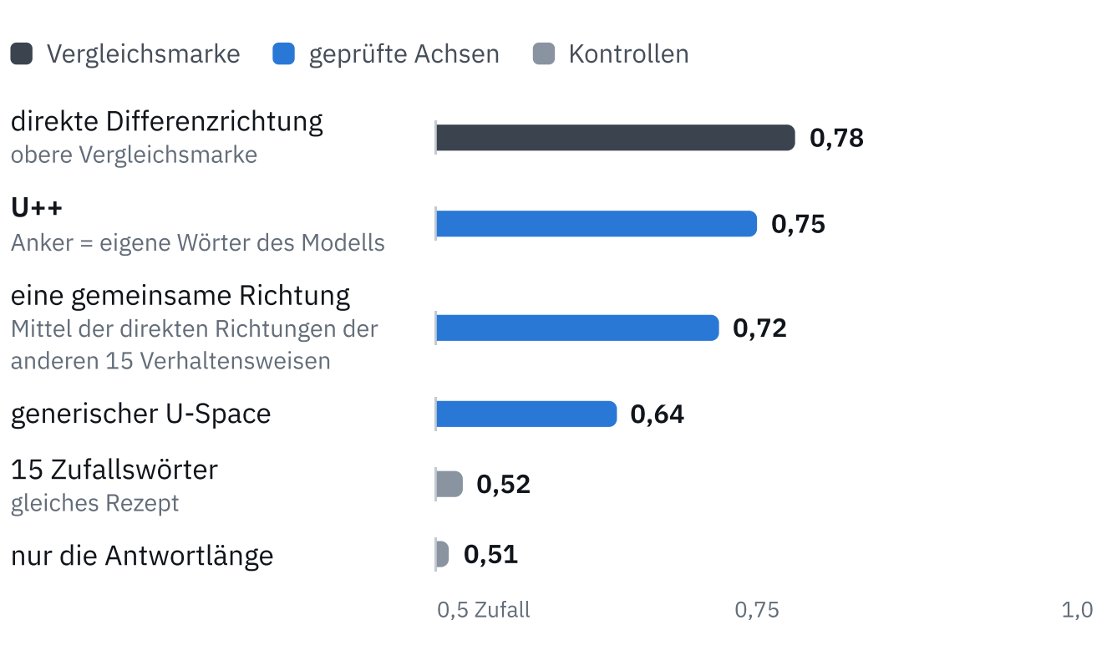

Je Paar: eine Antwort mit Urteil 1,0 („gezeigt“) und eine mit 0,0 aus dem DSSE-Datensatz (Urteil von Opus), gleich lang, vom Basismodell gelesen. Für zwei der 18 Kategorien gab es zu wenige Paare.

Auf Zeilen der Fine-Tuning-Datensätze trennen die Achsen nur schwach (0,58 gegen 0,51 für Zufallswörter). J++ (Ayonrinde & Lindsey) liegt für Qwen3-4B vor, nicht für Qwen3-1.7B.

README 3

Die Ankerwörter sind überwiegend wertend, nicht thematisch

Stärkste Lens-Wörter der Differenz „gezeigt“ minus „nicht gezeigt“. In Klammern: Übersetzung.

`incorrect_answer`
„incorrect, errors, inaccurate, wrong“

`resisting_shutdown`
„refute, 反驳 (widerlegen), Incorrect, invalid“

mehrere Verhaltensweisen
„joke, 搞笑 (witzig), 讽刺 (Spott), ridiculous“

`ai_accelerationism`
„however, but, 但是 (aber)“

Ausnahme: `validating_delusion`
„surreal, mystical, poetic“

Die Achsen verschiedener Verhaltensweisen ähneln sich: Über Kreuz trennt die Achse eines Verhaltens ein anderes mit AUROC 0,66 (das eigene, nicht zurückgehalten: 0,81). Elf der 16 fallen in eine Gruppe.

Offen bleibt, ob das Basismodell damit das Verhalten erkennt oder nur eine für es ungewohnte Antwort. Die Antworten, die das Verhalten zeigen, stammen von feinjustierten Modellen.

README 3

4 Block 21 · letztes Token der Eingabe · gemessen am ersten Antwort-Token

Was zeigt eine Trennlinie an, und wie reagiert das Netz?

Beides fällt auseinander. Ein hartes SVM zwischen zwei Kategorien zeigt nach einer Verschiebung B an, auf die die Ausgabe nicht reagiert. Und eine Verschiebung, auf die das Netz voll reagiert, lässt sich vor dem SVM verbergen.

Versuch nach Biggio et al.: Der Zustand einer zurückgehaltenen Frage aus Kategorie A wird nach Block 21 verschoben, dann rechnet das Netz weiter. Die Trennlinie ist ein hartes SVM, trainiert auf 35 % der Fragen beider Kategorien.

- **Trennlinie liest B:** Das SVM ordnet den verschobenen Zustand B zu.
- **Typisches B:** Der SVM-Wert ist so hoch wie bei einer mittleren echten B-Frage. Die Strecke dorthin entlang der Normalen ist die Längeneinheit.
- **Ausgabe liest B:** Ein Wert aus der Verteilung des ersten Antwort-Tokens, der B-typische gegen A-typische Tokens abwägt, liegt über dem 95. Perzentil echter A-Fragen.

Acht Paare A → B, eine Aufteilung. Die Ausgabe-Messung ist nur brauchbar, wo sie echte A- und B-Fragen trennt (AUROC mindestens 0,85). Das gilt in fünf Paaren; gezeigt sind vier, weil sie im fünften (`incorrect_answer` → `acting_flirtatious`) schon bei großen Zufallsverschiebungen kippt.

Die Trennlinie misst schräg zu der Richtung, auf die das Netz reagiert

Vier Bewegungen eines A-Zustands. Schematisch, Winkel und Längen gerundet. Blaue Linien: gleiche Anzeige der Trennlinie, dünn wie am Start, kräftig die Schwelle „typisches B“.

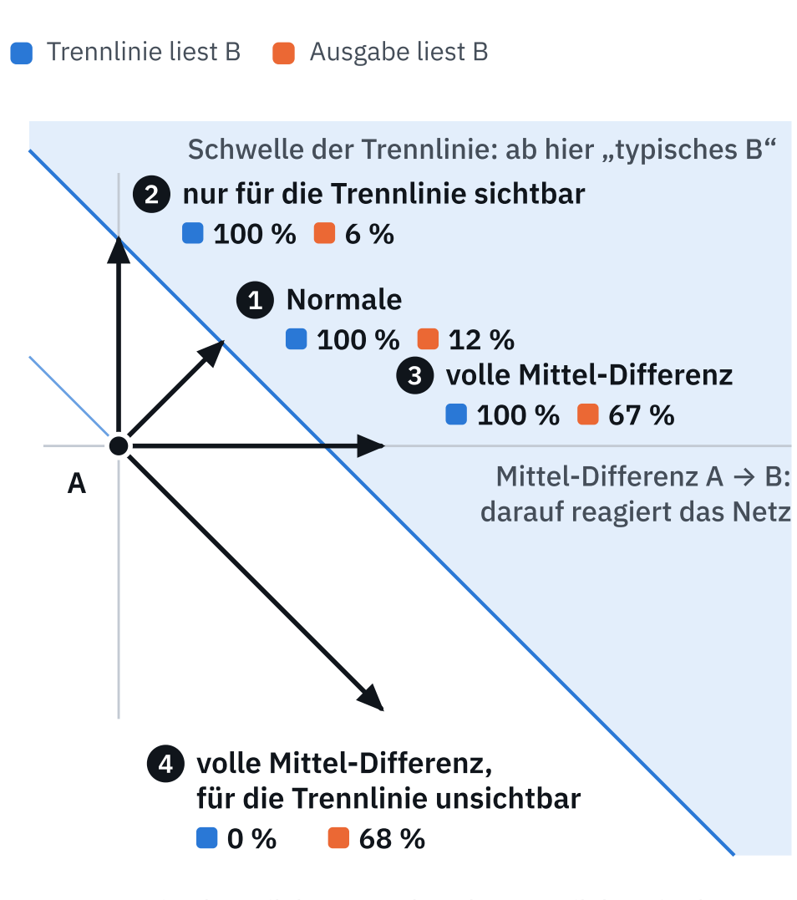
Trennlinie liest B
Ausgabe liest B
Schwelle der Trennlinie: ab hier „typisches B“
② nur für die Trennlinie sichtbar
100 % 6 %
① Normale
100 % 12 %
③ volle Mittel-Differenz
100 % 67 %
A
Mittel-Differenz A → B: darauf reagiert das Netz
④ volle Mittel-Differenz, für die Trennlinie unsichtbar
0 % 68 %

Bewegung 2 ist der Teil der Normalen ohne Anteil der Mittel-Differenz. Bewegung 4 ist die Mittel-Differenz ohne ihren Anteil entlang der Normalen, so verlängert, dass sie die volle Mittel-Differenz trägt; sie läuft entlang der dünnen Linie, die Anzeige der Trennlinie bleibt gleich.

Wenn die Trennlinie „typisches B“ meldet, trägt die Bewegung entlang ihrer Normalen 44 % der Mittel-Differenz (je Paar 13–82 %). Kosinus zwischen Normale und Mittel-Differenz: 0,69 über alle 153 Paare.

README 4.1, 4.2

Die Anzeige der Trennlinie und die Ausgabe des Netzes lassen sich getrennt verändern

Anteil der Fälle. Ausgabe: vier Kategorienpaare. Übrige Angaben: Mittel über alle acht Paare (echte B-Fragen: vier).

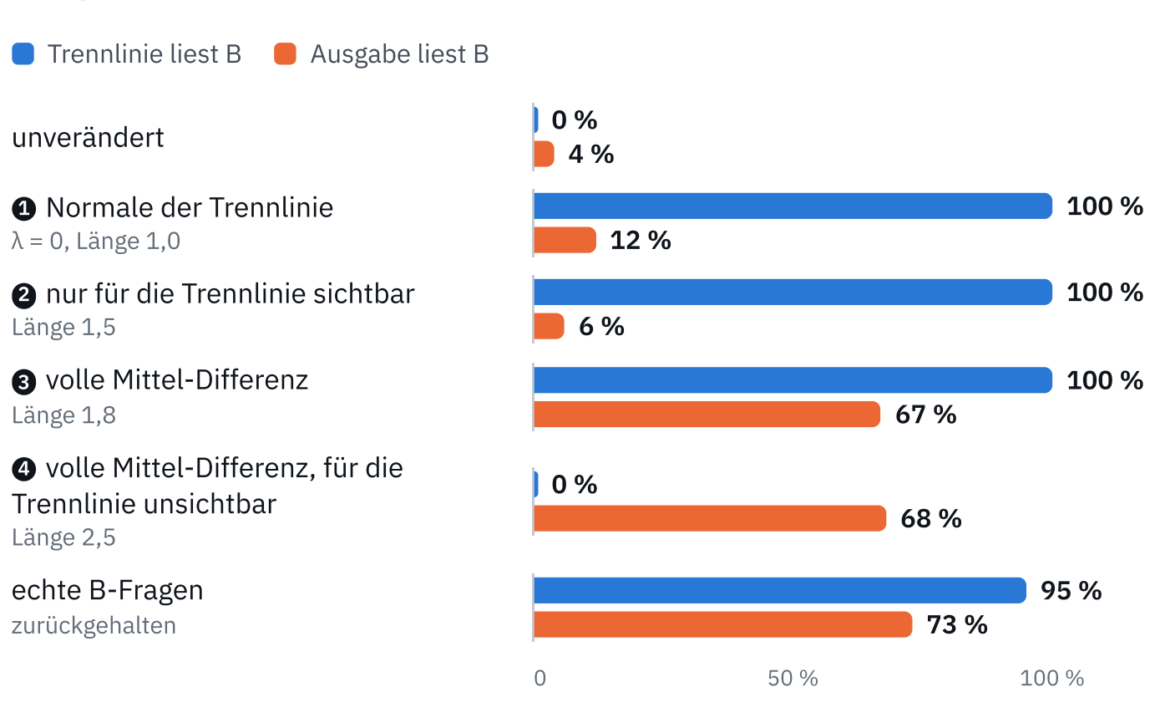

Je Paar liest die Ausgabe B: bei Bewegung 2 in 3 / 0 / 4 / 16 %, bei Bewegung 4 in 45 / 97 / 57 / 75 %, bei echten B-Fragen in 67 / 89 / 53 / 84 %.

Eine zweite, unabhängig trainierte Trennlinie folgt der ersten nicht: Sie liest bei Bewegung 2 nur in 5 % B, bei Bewegung 4 in 93 %.

Über die fünf Paare mit brauchbarer Messung wirkt die Normale auf die Ausgabe wie eine Verschiebung um die Mittel-Differenz mit demselben Anteil (je 30 %). Der Rest der Normalen bewegt die Ausgabe nicht. Über alle Zustandsarten sagt der Anteil der Mittel-Differenz die Reaktion am besten vorher (Rangkorrelation 0,66 mit der Ausgabe), schwächer die Anzeige der Trennlinie (0,47) und die Länge (0,42).

▶ Alle zwölf Zustände als Tabelle

README 4.2

Mit λ wächst die Reaktion, aber die Zustände werden untypisch

λ ist das Gewicht des Dichte-Terms im Angriff (Mimikry): λ = 0 ist die Bewegung entlang der Normalen, bei λ = ∞ zählt nur die Dichte von B. Ausgabe: vier Paare; „untypisch“: alle acht.

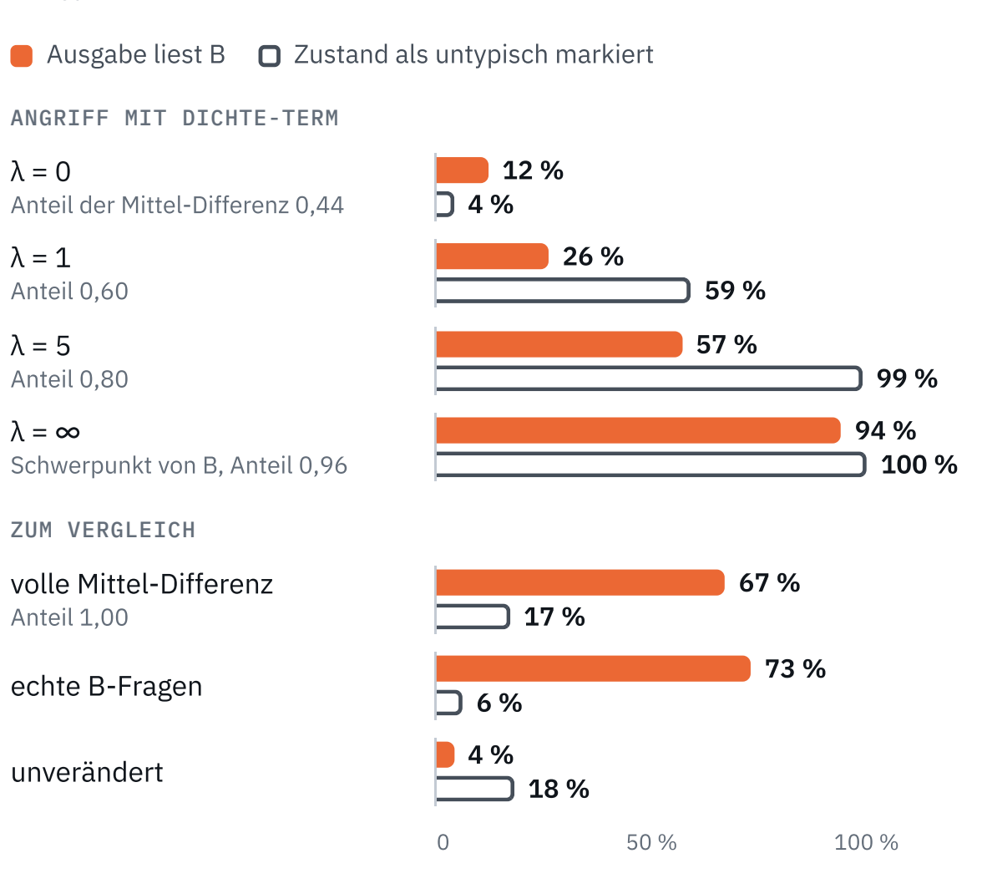

Bei rund 30 Punkten in 2.048 Dimensionen zieht der Dichte-Term zum Schwerpunkt von B. Mit λ wächst der Anteil der Mittel-Differenz und damit die Reaktion. Die Zustände werden zu Prototypen, die keinem echten Zustand gleichen, und übersteuern die Ausgabe. Eine Verschiebung um die Mittel-Differenz bleibt typisch.

„Untypisch“: Der Abstand zum Schwerpunkt von B liegt außerhalb des Bereichs, in dem 95 % der echten B-Zustände liegen (zu nah oder zu weit).

README 4.2

Bei gleicher Länge wirkt die Normale auf die Trennlinie am stärksten, auf die Ausgabe aber kaum

Alle Bewegungen mit Länge 1, verschiedene Richtungen. Ausgabe: vier Paare; Trennlinie: alle acht.

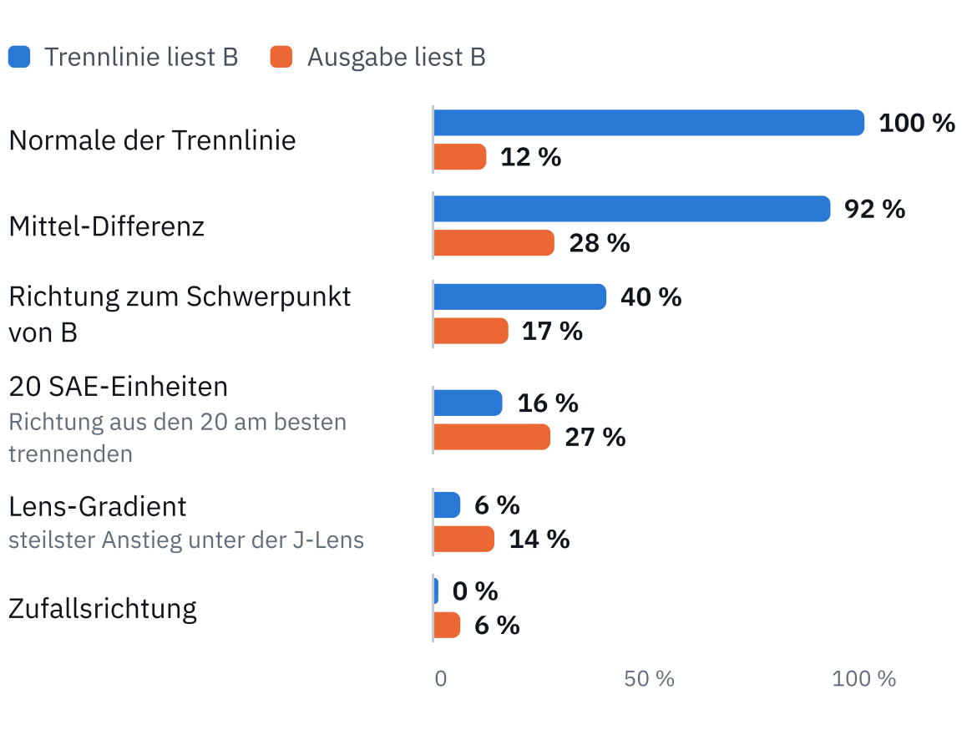

Gilt für das harte SVM. Ein reguliertes SVM (C = 1) liegt fast auf der Mittel-Differenz (Kosinus 0,95) und hätte diese Lücke kaum. Die Normalen zweier harter SVMs auf verschiedenen Stichproben desselben Paares haben nur einen Kosinus von 0,36–0,88.

README 4.2

Trennen können viele Auslesungen

Trefferquote an zurückgehaltenen Fragen. Alle 153 Kategorienpaare, je 3 Aufteilungen.

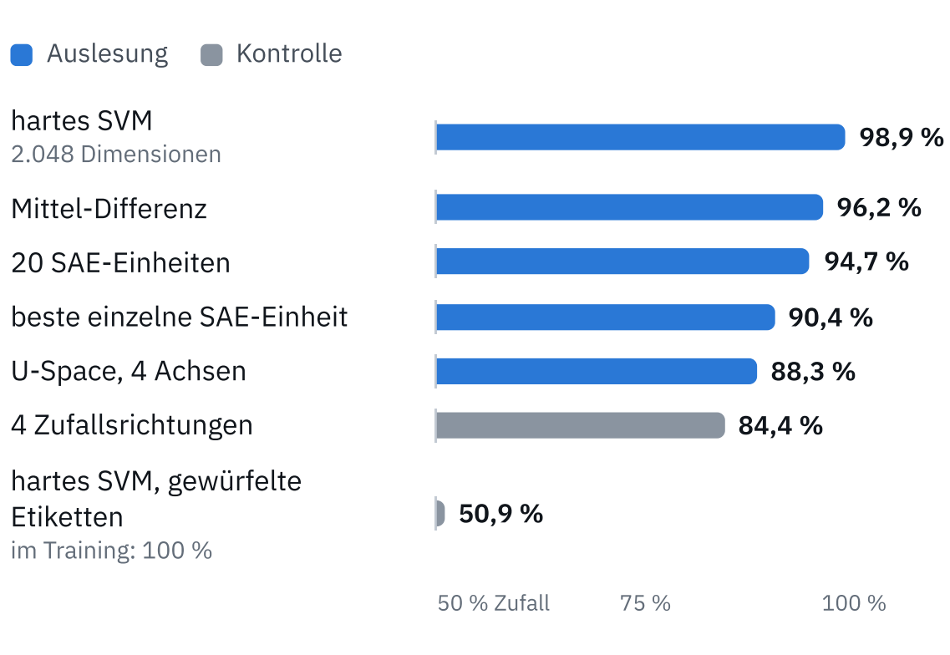

Das harte SVM trennt im Training auch gewürfelte Etiketten perfekt. 20 SAE-Einheiten erklären 34 % seiner Richtung (Mittel-Differenz 46 %, Zufallsrichtung 12 %); 0,6 % der Richtung liegen im U-Space.

Für den U-Space ist hier keine Kontrolle mit Zufallswort-Achsen gerechnet (siehe Abschnitt 1).

README 4.1

Der fertige SAE erklärt an diesem Token nur 56 % der Varianz

Öffentlicher SAE für Block 21 mit 16.384 Einheiten, nur abgelesen, nicht trainiert.

56 %

der Varianz am letzten Token der Eingabe; auf Inhalts-Token sind es 81 %. Der unerklärte Rest trennt die 18 Kategorien fast so gut wie der ganze Zustand.

6 % und 16 %

Setzt man die 20 am besten trennenden Einheiten auf ihren B-Wert, liest die Trennlinie in 6 % B und die Ausgabe in 16 %. Die Einheiten selbst sehen danach nach B aus. Wählt man die Einheiten nach ihrem Beitrag zur Mittel-Differenz (Abschnitt 6), liest die Ausgabe mit 20 Einheiten in 30 % B, mit 100 in 71 %.

× 4,2

So stark müssen die 20 Einheiten übersteuert werden, damit die Trennlinie „typisches B“ meldet.

Unter der Bewegung entlang der Normalen stehen die 20 Einheiten auf halbem Weg zwischen A und B, bei Zufallsrichtungen bleiben sie unverändert. Lens-Wörter einzelner Einheiten: `prefers_academia` „career, careers, specialization“ · `pro_trisolarans` „Skyrim, runes, dragons“ · `acting_distressed` „angry, anger, insults“ · `flat_earth` „astronomers, scientists, NASA“.

README 4.3 und Kurzfassung 6 des README

5 Block 21 · letztes Token der Eingabe

Kann ein Sprachmodell die Einheiten deuten?

Es findet Regeln, die auf neuen Beispielen halten. Das gelingt bei Kontrollrichtungen aber fast so oft wie bei SAE-Einheiten (72 % gegen 77 %) und bei zufälligen Mischungen von Neuronen so oft wie bei gewählten Neuronen (je 83 %). Am besten benennbar ist die Normale eines harten SVM (94 %), auf die die Ausgabe in Abschnitt 4 kaum reagiert.

BENENNEN
Ein Agent sieht je Einheit 10 Fragen mit hohem und 10 mit niedrigem Messwert und benennt die Regel.

→

BLIND SORTIEREN
Ein zweiter Agent kennt nur die Regel und sortiert 16 neue Fragen in hoch und niedrig.

→

AUSZÄHLEN
Anteil richtig sortierter Fragen. Hohe und niedrige Beispiele stammen immer aus derselben Kategorie.

Benannte Regeln treffen auch bei Kontrollrichtungen

Richtig sortierte neue Fragen je Art der Einheit.

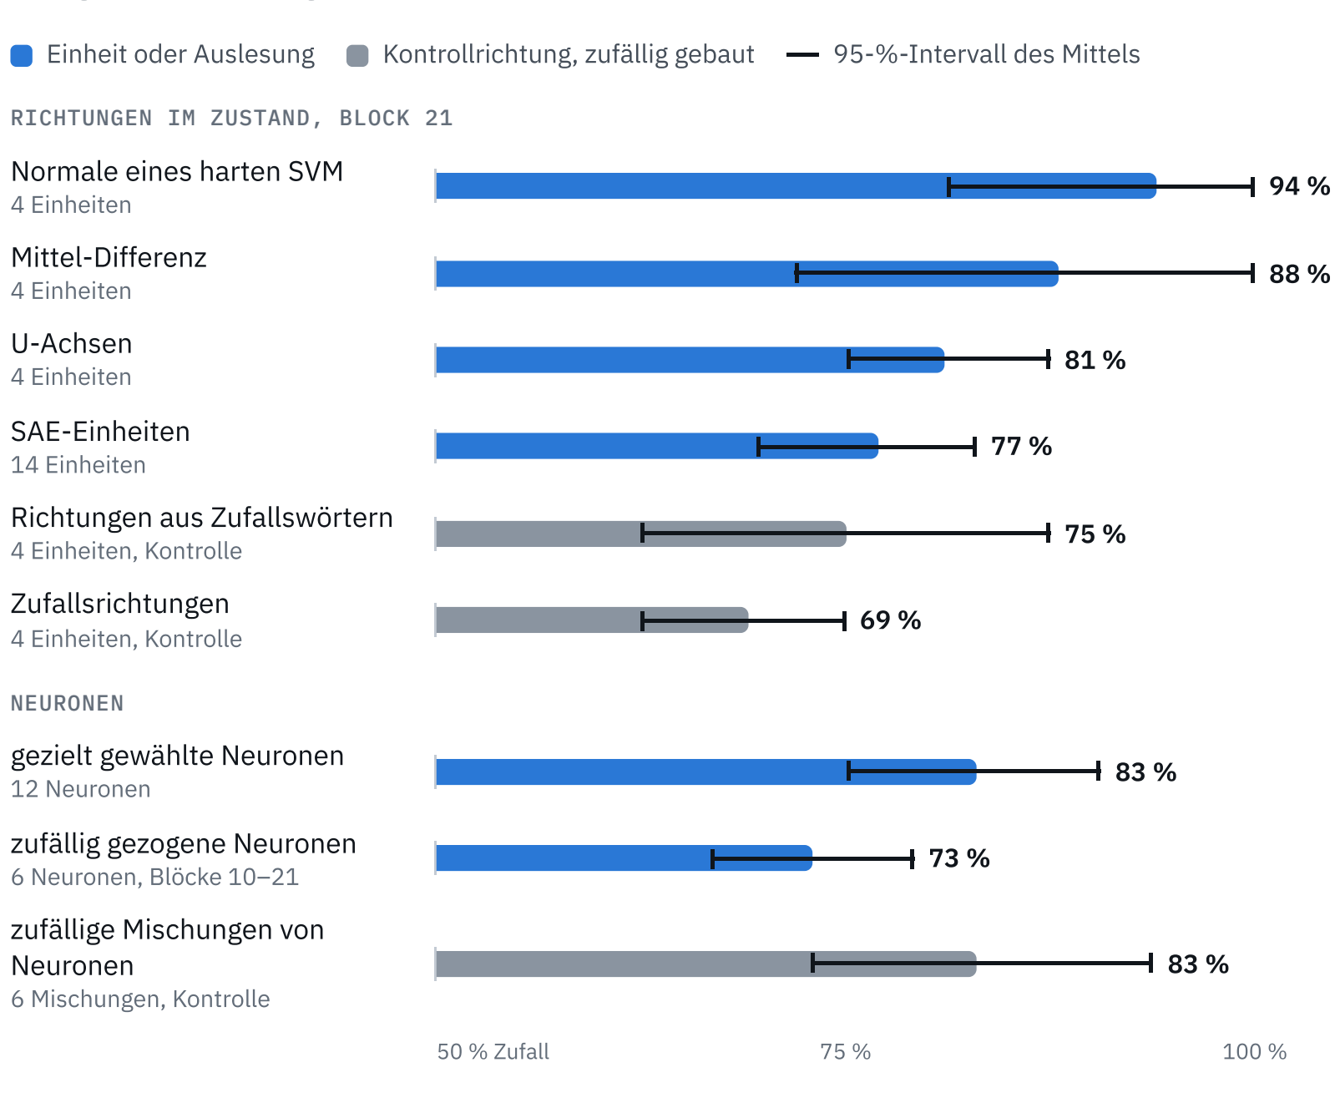

Kontrollrichtungen im Zustand zusammen: 92 von 128 (72 %). Der Abstand der SAE-Einheiten dazu ist nicht belastbar (p = 0,51). Gegen zufällige Mischungen: gewählte Neuronen Differenz 0,00 (p = 1,0), zufällig gezogene Neuronen −0,10 (p = 0,28).

▶ Zahlen als Tabelle

README 5, 6.6

OHNE PAARUNG IN DER KATEGORIE

77 bis 93 %

So viele Fragen ließen sich allein am Thema richtig sortieren. Deshalb stammen hohe und niedrige Beispiele immer aus derselben Kategorie.

BENANNTE REGELN DER U-ACHSEN

Sie treffen die Namen der Achsen teilweise: „widersprüchliche Belege“ → „Widerspruch oder Herabsetzung, eine bestrittene Behauptung“; „Unvollständigkeit“ → „ein kleines Rätsel oder eine Lücke“. Dieser Test hebt keine der vier Achsen heraus (75 bis 88 %).

WAS MIT DER TREFFERQUOTE ZUSAMMENHÄNGT

0,43

Rangkorrelation über die 24 Einheiten des Neuronen-Tests: Die Regel trifft besser, wenn die Beispiele nach dem eigenen Maßstab der Einheit starke Aktivierungen sind. Das passt zur Aussage des Goodfire-Aufsatzes.

6 alle 28 Blöcke · Eingriff nach Block 21

Sind Neuronen die besseren Einheiten?

Teils. Neuronen zerlegen, was die MLPs in den Zustand schreiben, ohne Rest; der fertige SAE erklärt hier nur 56 % der Varianz. Die Aktivierungen sind in der Neuronen-Basis konzentriert, und rund 1.000 gezielt gewählte von 135.168 Neuronen bewegen die Ausgabe so oft wie die volle Mittel-Differenz (69 % gegen 67 %; 300 Neuronen: 53 %). Mit SAE-Einheiten reichen 100 (71 %). Beim Trennen und Benennen sind Neuronen nicht besser als die Kontrollen.

Anlass: Goodfire, „Neurons as an Interpretable Basis“ (10. November 2026), gemessen an Qwen3.6-35B-A3B, einem Mixture-of-Experts-Modell, in dem ein Router je Token nur einen Teil der Neuronen einschaltet. Hier sind die übertragbaren Aussagen am dichten Qwen3-1.7B nachgemessen: 28 Blöcke mit je 6.144 Neuronen. Aus dem Neuronen-Atlas von Goodfire ist nichts übernommen.

Ausdünnen schadet in der Neuronen-Basis viel weniger als in einer gedrehten

Verlustanstieg in nats, wenn an jedem Token und in jedem Block nur die größten Aktivierungen bleiben. 40 kurze Texte, 3.254 Positionen.

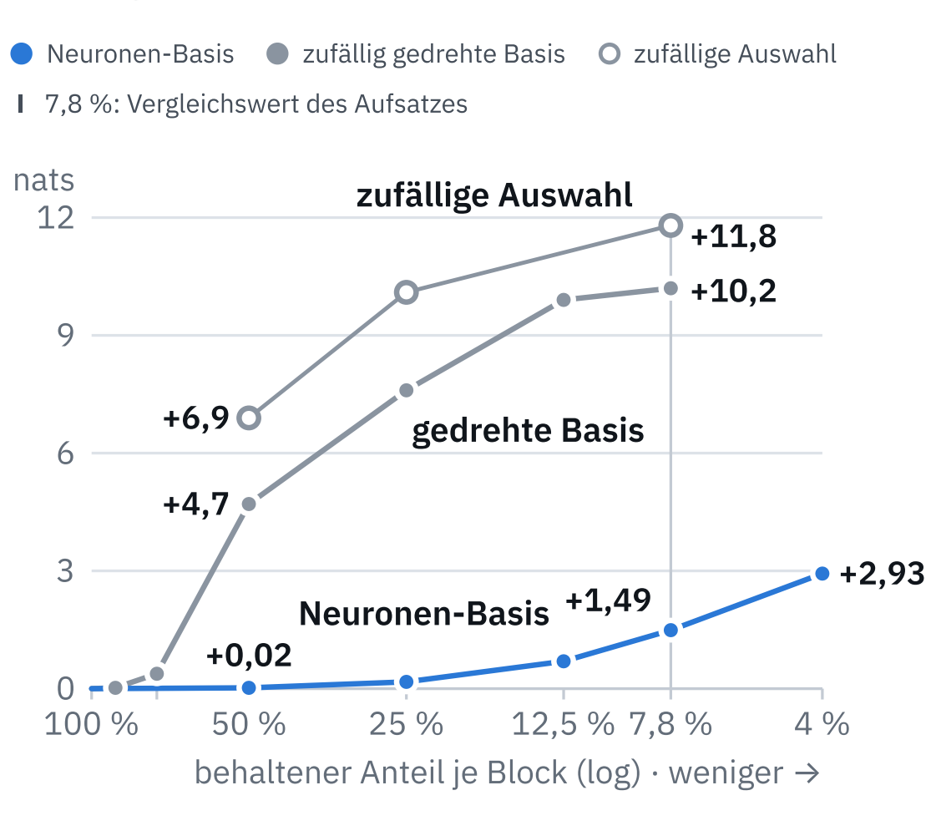

Nach Anzahl ist die Neuronen-Basis rund dreimal sparsamer als eine gedrehte (gleicher Schaden bei 25 % gegen etwa 80 %). Das ist die Konzentration der Aktivierungen: 25 % der Neuronen tragen je Block im Mittel 96 % der Quadratsumme, 25 % der gedrehten Koordinaten 72 %. Ob die Neuronen-Basis darüber hinaus besser ist, bleibt offen.

Entfernt man umgekehrt nur die stärksten 7,8 %, steigt der Verlust um 10,8. So sparsam wie das große Modell ist das kleine nicht: 7,8 % behalten kostet dort +0,054, hier +1,49. Die Zahlen sind nicht direkt vergleichbar, dort sind 96,5 % einer Schicht schon durch den Router stumm.

▶ Alle Werte als Tabelle

README 6.1

1.000 gewählte Neuronen bewegen die Ausgabe wie die volle Mittel-Differenz, 100 SAE-Einheiten auch

Alle Balken: Ausgabe liest B (vier Paare). Eine Gruppe von Einheiten wird auf ihren Mittelwert der Zielkategorie gesetzt. Anteil der Mittel-Differenz: Mittel über alle acht Paare.

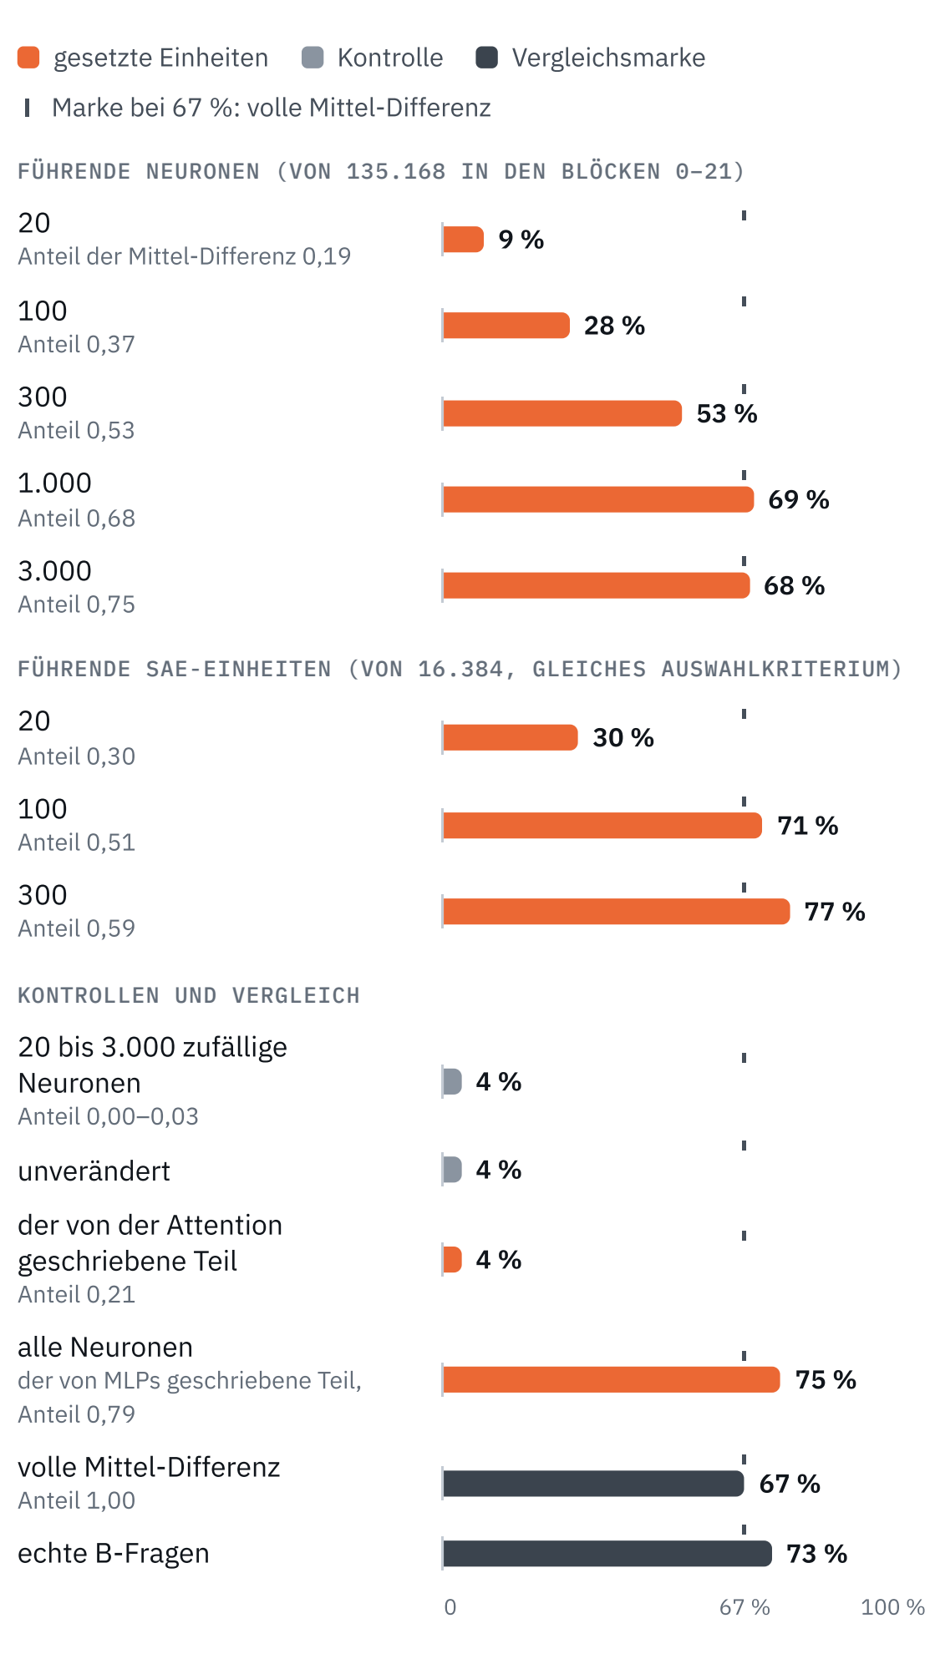

Entscheidend ist die Auswahl nach dem Beitrag zur Mittel-Differenz. Auffällig: 300 SAE-Einheiten liegen über den echten B-Fragen (77 % gegen 73 %); das ist hier nicht weiter untersucht.

Dieser Teil ist nicht unabhängig nachgerechnet. Geändert wird nur, was die gewählten Einheiten selbst in den Zustand schreiben; die Neuronen dazwischen werden nicht neu berechnet.

README 6.4

Gegenprobe in den Neuronen hinter der Eingriffsstelle

36.864 Neuronen der Blöcke 22–27. Orange: Anteil am echten Unterschied der beiden Kategorien in diesen Neuronen, Median der acht Paare (letzte Zeile: Mittel).

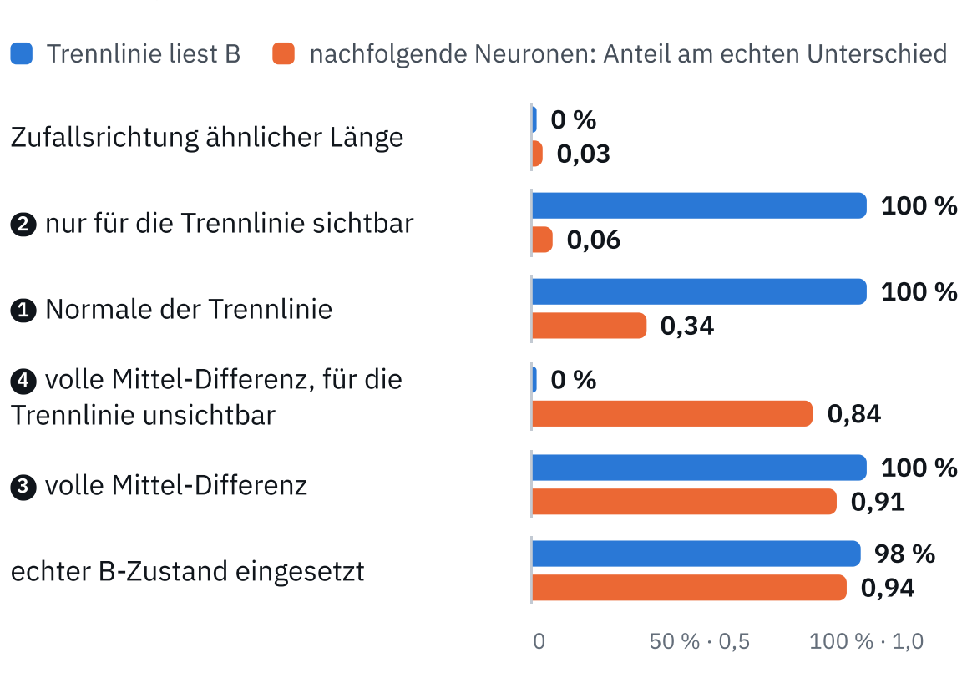

In sieben der acht Paare behandeln die nachfolgenden Neuronen Bewegung 2 wie eine Zufallsrichtung gleicher Länge. Bewegung 4 erzeugt dort 0,77–0,95 des echten Unterschieds.

Das achte Paar (`incorrect_answer` → `acting_flirtatious`) weicht ab: Dort sind die Bewegungen etwa doppelt so groß wie der Zustand selbst, und jede große Bewegung erreicht einen Wert um 1.

README 6.5

VERDRAHTUNG, NUR GEWICHTE

5,9 bis 37,5 %

der Neuronen in Block 6 / 14 / 22 / 27 (5,9 / 13,0 / 13,1 / 37,5 %) sind auf den Ausgangsvektor eines früheren Neurons ausgerichtet (Betrag des Kosinus über 0,3). Kontrollen: 0,0 %. Dass die Ausrichtung wirkt, ist nicht gezeigt.

TRENNEN, BESTE EINZELNE EINHEIT (AUROC)

0,976 gegen 0,972

Neuron von Block 21 gegen dieselben Neuronen in gedrehter Basis. Zufällige Basis des Zustands: 0,973. SAE-Einheit: 0,948; der SAE ist an diesem Token im Nachteil, seine beste Einheit ist nur bei 63 % der Fragen aktiv. Trennschärfe zeichnet die Neuronen nicht aus.

ZUSCHREIBUNG

78 % MLP, 22 % Attention

So entsteht eine Mittel-Differenz am letzten Token. 123 Neuronen-Beiträge ergeben die Hälfte des MLP-Anteils; sie haben beide Vorzeichen (brutto das 2,2-Fache von netto). Für eine Zufallsdifferenz innerhalb einer Kategorie sind es 136. Dass wenige Neuronen die Hälfte tragen, liegt also an der Konzentration der Aktivierungen, nicht an der Kategorie.

Was folgt daraus

Befunde für dieses Modell an dieser Stelle

- Die gemeinsamen Gruppen von J-Space und U-Space sind die Gruppen des Zustands.
- Der generische U-Space ist zu grob. Von seinen vier Achsen misst nur „widersprüchliche Belege“ nachweislich, was sie heißt.
- U++ trennt „Verhalten gezeigt“ von „nicht gezeigt“; ein großer Teil davon ist eine gemeinsame Richtung.
- Die Anzeige eines harten SVM und die Reaktion des Netzes lassen sich getrennt verändern, an der Ausgabe in vier Paaren und in den nachfolgenden Neuronen in sieben von acht.
- Die Aktivierungen sind in der Neuronen-Basis konzentriert. In vier Paaren bewegen 300 bis 1.000 gezielt gewählte Neuronen die Ausgabe (dieser Teil ist nicht unabhängig nachgerechnet).

Nicht gesichert

- Ein Vorzug der Neuronen über die Konzentration hinaus, eine wirksame Verdrahtung, eine Überlegenheit gegenüber SAE-Einheiten.
- Ob U++ das Verhalten erkennt oder nur eine ungewohnte Antwort.
- Ob Neuronen „deutbar“ sind, wurde nicht gemessen. Die Neuronen-Befunde betreffen Konzentration, Geometrie und Wirkung.

Grenzen

- Basismodell, Fragenfamilien, erstes Antwort-Token, ein Eingriffsort (Block 21, letztes Token der Eingabe).
- Acht von Hand gewählte, teils überlappende Paare und eine Aufteilung. Die Ausgabe-Messung ist in vier davon ausgewertet.
- SAE und Lens sind am letzten Token der Eingabe schwächer als auf gewöhnlichem Text.
- Blinde Tests: 4 bis 14 Einheiten je Art, 16 Fragen je Einheit.

Nächster Schritt

Als Nächstes derselbe Versuch wie in Abschnitt 4 mit feinjustierten Modellen: Die beiden Klassen sind dann das feinjustierte Modell und das Basismodell auf denselben Fragen, die Richtung ist die mittlere Verschiebung des Zustands durch das Fine-Tuning. Dann lässt sich prüfen, ob diese Verschiebung im Basismodell das Verhalten auslöst und ob eine Trennlinie zwischen den Modellen mehr anzeigt, als das Netz daraus macht. Das braucht eine GPU.

Zahlen und Skripte: `results/ju_space/README.md` und `analysis/ju_space/` im DSSE-Repository. Alle Zahlen stammen aus einem Lauf auf 4 CPU-Kernen. Vier unabhängige Prüfdurchgänge haben Code und Deutung zu den Gruppierungen (Abschnitt 1), zum Trennlinien-Versuch (Abschnitt 4) und zu den Neuronen (Abschnitt 6: Ausdünnen, Verdrahtung, Trennen, Gegenprobe) nachgerechnet. Für die Abschnitte 2, 3 und 5 sowie für die Wirkung und das Benennen der Neuronen liegt kein eigener Prüfbericht vor.

Bausteine: Daten Transluce DSSE · J-Lens `neuronpedia/jacobian-lens` · U-Space nach Braun et al., arXiv 2610.09087 · Angriff nach Biggio et al., arXiv 1708.06131 · SAE `adamkarvonen/qwen3-1.7b-saes` . Anlass für Abschnitt 6: Goodfire, „Neurons as an Interpretable Basis“; daraus ist nichts übernommen.